CAMPOS IA

AULA 02

AULA 02 — Sistemas Operacionais Linux e Terminal CLI em Ciência de Dados

Apostila didática • Teoria, comandos comentados, laboratório, exercícios e gabarito

1. Objetivos de aprendizagem

• Compreender por que Linux e o terminal CLI são amplamente usados em ciência de dados, computação em nuvem e treinamento de IA.

• Organizar arquivos e diretórios pela linha de comando.

• Inspecionar processos e acompanhar o uso de CPU, memória e GPU.

• Combinar comandos com pipes para criar fluxos de processamento.

• Filtrar logs e transformar dados textuais com grep, awk e sed.

2. Por que Linux é importante em Ciência de Dados

• O Linux é muito utilizado em servidores, máquinas virtuais, ambientes de nuvem e clusters de treinamento. Nesses ambientes, a interface gráfica pode não estar instalada ou não ser a forma mais eficiente de operar.

• O terminal (CLI, Command Line Interface) permite executar tarefas de forma precisa, repetível e automatizável. É comum usá-lo para preparar dados, iniciar experimentos, acompanhar treinamentos, consultar logs e administrar recursos computacionais.

• Uma sequência de comandos pode ser registrada em um script e repetida em diferentes máquinas, favorecendo reprodutibilidade.

3. Navegação e organização do filesystem

• pwd mostra o diretório atual. ls lista arquivos e pastas; ls -la inclui arquivos ocultos e detalhes como permissões, proprietário, tamanho e data.

• cd caminho muda de diretório. cd .. sobe um nível; cd ~ vai para a pasta pessoal.

• mkdir nome cria uma pasta. mkdir -p projeto/dados/brutos cria toda a estrutura intermediária necessária.

• Exemplo: mkdir -p projeto/{dados, modelos, logs, scripts}. Em shells compatíveis com expansão de chaves, isso cria quatro diretórios dentro de projeto.

4. Processos, desempenho e GPU

• ps aux apresenta uma fotografia dos processos em execução. É útil para localizar processos Python e verificar consumo de CPU e memória.

• top oferece monitoramento interativo e atualização contínua. htop é uma alternativa mais visual, quando instalada.

• nvidia-smi apresenta informações sobre GPUs NVIDIA compatíveis: utilização, memória, temperatura e processos associados. O comando depende de driver NVIDIA instalado e de hardware compatível.

• Para localizar um processo Python: ps aux | grep python. Lembre-se de que o próprio grep pode aparecer na busca.

5. Pipes Unix: conectando ferramentas

• O caractere | (pipe) envia a saída padrão de um comando para a entrada padrão do próximo. Assim, ferramentas pequenas podem ser combinadas.

• Exemplo: ps aux | grep python | grep -v grep. Primeiro lista processos, depois filtra os que contêm python e remove a linha do próprio grep.

• Exemplo: cat treino.log | grep -i 'epoch'. O arquivo é lido e as linhas contendo epoch são selecionadas sem precisar abrir o log em um editor.

6. grep: localizar padrões em logs

• grep 'erro' treino.log procura a palavra erro. grep -i ignora diferenças entre maiúsculas e minúsculas; grep -n mostra números das linhas; grep -E aceita expressões regulares estendidas.

• Exemplo: grep -inE 'error|warning|nan' logs/treino.log. O comando destaca ocorrências que merecem investigação.

• Use aspas para proteger padrões que contenham espaços ou caracteres especiais.

7. awk: processamento tabular

• awk lê texto linha a linha e divide cada linha em campos. Por padrão, os campos são separados por espaços ou tabulações; para CSV simples, pode-se definir -F,.

• Exemplo para CSV sem campos contendo vírgulas entre aspas: awk -F, 'NR==1 {print; next} {print $1, $3}' dados.csv.

• NR representa o número do registro; $1, $2 etc. representam campos. Em arquivos CSV complexos, com vírgulas dentro de campos entre aspas, prefira uma biblioteca própria de CSV, como Python csv ou pandas.

8. sed: transformação de texto

• sed aplica transformações em fluxo, sem exigir que o arquivo inteiro seja carregado em memória.

• Exemplo: sed 's/DEBUG/INFO/g' app.log imprime o texto com todas as ocorrências de DEBUG substituídas por INFO.

• Exemplo: sed -n '1,20p' treino.log mostra as primeiras 20 linhas. Para editar o arquivo diretamente, existe a opção -i, mas faça cópia de segurança antes.

9. Laboratório guiado

• 1) Crie a estrutura: mkdir -p aula02/{dados,logs,saidas,scripts}.

• 2) Confira a localização: pwd; ls -la; ls -la aula02.

• 3) Crie um log de teste: printf 'Epoch 1 loss=0.91\nEpoch 2 loss=0.72\nWARNING GPU memory high\nEpoch 3 loss=0.54\n' > aula02/logs/treino.log.

• 4) Filtre épocas: grep -i 'epoch' aula02/logs/treino.log.

• 5) Conte ocorrências: grep -ic 'epoch' aula02/logs/treino.log.

• 6) Transforme o rótulo: sed 's/WARNING/ATENCAO/g' aula02/logs/treino.log.

• 7) Combine comandos: cat aula02/logs/treino.log | grep -i 'loss'.

• 8) Observe recursos: top; em equipamento NVIDIA compatível, execute nvidia-smi.

10. Boas práticas e segurança

• Confira o diretório atual com pwd antes de executar comandos que alterem arquivos.

• Evite executar comandos destrutivos sem compreender seus argumentos. Atenção especial a rm, rm -r, permissões e comandos com sudo.

• Não exponha senhas, tokens ou dados pessoais em logs compartilhados.

• Registre comandos, versões de ferramentas, parâmetros e resultados para tornar experimentos reproduzíveis.

• Use awk apenas para CSV simples; para CSV com aspas, separadores complexos ou dados ausentes, utilize pandas ou o módulo csv do Python.

11. Exercícios de fixação

• 1) Qual comando mostra arquivos ocultos e detalhes de permissões?

• 2) Qual é a função de mkdir -p?

• 3) Explique a diferença entre ps aux e top.

• 4) O que o pipe | faz?

• 5) Escreva um grep que procure error sem diferenciar maiúsculas/minúsculas e mostre o número da linha.

• 6) Em awk, o que representam NR e $2?

• 7) O que faz sed 's/cat/dog/g' arquivo.txt?

• 8) Por que awk -F, não é suficiente para todo arquivo CSV?

12. Gabarito

• 1) ls -la. 2) Cria diretórios intermediários quando necessário. 3) ps aux é uma listagem pontual; top atualiza a visualização continuamente. 4) Encaminha a saída de um comando para a entrada do próximo. 5) grep -in 'error' arquivo. 6) NR é o número do registro; $2 é o segundo campo. 7) Substitui todas as ocorrências de cat por dog na saída. 8) Porque CSV permite campos entre aspas contendo vírgulas e regras de escape.

13. Glossário

• CLI: interface de linha de comando. Filesystem: sistema de arquivos. Processo: programa em execução. GPU: unidade de processamento gráfico. Log: registro de eventos. Pipe: conexão entre saída e entrada de comandos. Cluster: conjunto de computadores que trabalham em conjunto.

14. Referências para estudo

• GNU Coreutils — documentação dos utilitários básicos: https://www.gnu.org/software/coreutils/manual/

• GNU grep — manual: https://www.gnu.org/software/grep/manual/

• GNU awk — documentação: https://www.gnu.org/software/gawk/manual/

• GNU sed — manual: https://www.gnu.org/software/sed/manual/

• htop — projeto e documentação: https://htop.dev/

• NVIDIA System Management Interface (nvidia-smi): https://docs.nvidia.com/deploy/nvidia-smi/